

# Ένα Πλήρες LLM Training Studio σε Ένα Αρχείο Κώδικα.

Τοπική εκπαίδευση, ρύθμιση και δοκιμή μοντέλων γλώσσας (όπως το Qwen2.5-Coder) αποκλειστικά για Python κώδικα.

Χωρίς πολύπλοκα scripts. Χωρίς άγχος για τη VRAM.

PySide6 Desktop GUI

HF Hub Native


Auto Pipeline

Multi-GPU Ready



# Από Διασκορπισμένα Scripts σε Ένα Ενιαίο Κέντρο Ελέγχου

Πριν (Το Χάος)



Μετά (Το Studio)



Όλη η αλυσίδα εργαλείων — από την αναζήτηση του Μοντέλου Βάσης μέχρι το Supervised Fine-Tuning και τη ζωντανή δοκιμή — ενορχηστρώνεται τοπικά και αρμονικά.

## Auto Pipeline

100%

Συλλογή → Προεπεξεργασία → Εκπαίδευση  
με το πάτημα του κουμπιού 🚀 Auto.

## Hardware Intelligence

RTX 3060 12GB (ασφαλές)



Αυτόματη ρύθμιση υπερπαραμέτρων (Batch, LoRA rank) βάσει της VRAM της κάρτας σας.

## Hugging Face Integration

qwen coder




Αναζήτηση, κατέβασμα και direct ανέβασμα  
του τελικού μοντέλου στο Hub.

## Built-in Chat & Inference



Ζωντανή δοκιμή prompt, Multi-turn συνομιλία  
και A/B testing μεταξύ Base και Final Model.


# Η Αρχιτεκτονική του Ενιαίου Συστήματος.



## Subprocess Isolation


Τα βαριά στάδια εκπαίδευσης εκτελούνται ως αυτόνομες διεργασίες στο παρασκήνιο. Το UI παραμένει 100% ανταποκρίσιμο και τα logs μεταφέρονται σε πραγματικό χρόνο (100ms cadence).

# Η Ροή των 7 Σταδίων: Από Raw Data σε Custom AI.



Η επιλογή STAGE\_CHOICES επιτρέπει την εκτέλεση ολόκληρης της διαδρομής αυτόματα ή την επανεκκίνηση από οποιοδήποτε μεμονωμένο βήμα.

# Ενσωματωμένη Ανακάλυψη & Διαχείριση Μοντέλων.



## ☒ Smart Search Algorithm

Πριμοδοτεί μοντέλα με tags coder, python και δίνει bonus βαθμολογία στη σειρά Qwen.

## ☒ Local Integrity (.studio\_integrity.json)

Ελέγχει αυτόματα αν λείπουν αρχεία config, tokenizer ή βαρών (safetensors, bin) πριν ξεκινήσει η εκπαίδευση.

## ☒ Seamless Download

Κατεβάζει snapshot στο Base\_Models/ με υποστήριξη για Gated repositories μέσω HF Token.

# Continued Pretraining (CPT) vs. Supervised Fine-Tuning (SFT).

## Στάδιο 3

```
def load_data():  
    data = json.load(open('raw.json'))  
    return data  
  
for item in data:  
    process(item)  
  
class Model:  
    def train():  
        pass  
  
import pandas as pd  
df = pd.read_csv('file.csv')
```



### Απορρόφηση Γνώσης.

Το μοντέλο διαβάζει χύμα κώδικα (Domain Adaptation). Στόχος είναι το next-token prediction για να μάθει τις ιδιαιτερότητες της βάσης κώδικά σας.


## Στάδιο 5

```
[Instruction] Summarize this function:  
def process(data):  
    pass  
  
[Response] The function processes data.  
  
[Instruction] Fix the bug in the following code:  
def process(data):  
    pass  
  
[Response] The process(data):  
df = pd.read_csv('pro')
```

### Μορφοποίηση Συμπεριφοράς.

Το μοντέλο μαθαίνει να απαντά σε οδηγίες (Instruction/Response format). Στόχος είναι να δημιουργηθεί συμπεριφορά Chat/Assistant.

# Υπερπαράμετροι & Ανατομία του LoRA.



# Έξυπνη Διαχείριση Υλικού: Auto-Tuning Profiles.


| VRAM Tiers:                   | 8GB      | 12GB      | 24GB+    |
|-------------------------------|----------|-----------|----------|
| <micro_batch_size>            | Micro 1  | Micro 1   | Micro 2  |
| <gradient_accumulation_steps> | Accum 32 | Accum 16  | Accum 16 |
| <max_length>                  | Max 1024 | Max 2048  | Max 4096 |
| <precision>                   | fp16     | bf16/fp16 | bf16     |



## Effective Batch Size $\approx 32$ .

Ανεξάρτητα από το αν έχετε RTX 3050 ή 4090, το Studio ρυθμίζει αυτόματα το  $\text{micro\_batch} \times \text{grad\_accum}$  ώστε να στοχεύει πάντα σε βέλτιστη απόδοση μάθησης.

# Δυναμική Προσαρμογή Βάσει Μεγέθους (Model Size Hints).



Ο κώδικας ανιχνεύει αυτόματα τις παραμέτρους του επιλεγμένου μοντέλου (MODEL\_SIZE\_HINTS).

**Μοντέλα 1.5B:** Προσαρμογή με μεγαλύτερο Learning Rate ( $2e-4$ ).

**Μοντέλα 72B:** Δυναμική μείωση Learning Rate ( $3e-5$ ) για σταθερότητα και διπλασιασμός του LoRA rank scale.

Το UI προσαρμόζεται σιωπηλά και έξυπνα. Δεν χρειάζεται να είστε AI expert.

# Ασπίδα Προστασίας Out of Memory (VRAM Management).

1

## Αρχιτεκτονική Subprocess

Τα training steps τρέχουν σε αυτόνομες διεργασίες. Όταν το στάδιο τελειώνει, η μνήμη απελευθερώνεται πλήρως στο OS.

2

## Έξυπνο Cleanup

Συνδυασμός `gc.collect`, `torch.cuda.empty_cache`, και `ipc_collect` καθαρίζει τα υπολείμματα μεταξύ των σταδίων.

3

## Automatic Prevention

Το `gradient_checkpointing` είναι πάντα ενεργό, διασώζοντας τεράστια ποσά VRAM με αντάλλαγμα ελάχιστο χρόνο υπολογισμού.

# Ζωντανή Δοκιμή & Αξιολόγηση (Inference).

Δυνατότητα άμεσης εναλλαγής (A/B Testing) μεταξύ αρχικού και τελικού μοντέλου.

1

Μοντέλο Βάσης ☒ Τελικό export

Το εργαλείο διαθέτει ενσωματωμένο Multi-turn Chat.

2

## System Prompt & User Prompt

You are an AI programming assistant.

User: Write a Python function to reverse a string.

## Output

Here is the Python function:

```
def reverse_string(s):  
    return s[::-1]  
  
# Example usage:  
print(reverse_string('hello'))
```

## Generation Params

Temperature: 0.7

Top-p: 0.9

3

Άμεσος έλεγχος θερμοκρασίας και δειγματοληψίας.

# Στάδιο 7: Export & Hub Manager.



## ✓ Βάρη Safetensors

Συγχώνευση (merge) των LoRA adapters απευθείας στο Base Model για μέγιστη συμβατότητα.

## ✓ One-Click Upload

Χρήση του HF\_TOKEN για απευθείας ανέβασμα σε Public ή Private repositories.

## ✓ Quick Test

Φορτώστε και δοκιμάστε οποιοδήποτε online μοντέλο απευθείας από το Hub πριν το κατεβάσετε μόνιμα.

# Quick Start: Τα 4 Βήματα της Επιτυχίας.

1

## Ρύθμιση

Επίλεξε τον Python Interpreter και το GPU Profile σου.

2

## Λήψη

Αναζήτησε και κατέβασε το Μοντέλο Βάσης (π.χ. Qwen/Qwen2.5-Coder-1.5B).

3

## Δεδομένα

Βάλε τα Python αρχεία σου στους φακέλους του artifacts/01\_collect/.

4

## Εκτέλεση

Πάτα 🚀 Auto και άφησε το Studio να αναλάβει.

# Από Raw Κώδικα σε Custom LLM.

## Χωρίς Κώδικα (No-Code Pipeline)

Μηδενική ανάγκη  
συγγραφής  
custom training  
scripts.

## Τοπική Ασφάλεια (Local Privacy)

Τα δεδομένα και  
ο κώδικας δεν  
εγκαταλείπουν  
ποτέ το μηχάνημά  
σας.

## Multi-GPU Ready

Αυτόματη  
βελτιστοποίηση  
ανεξαρτήτως  
υλικού.

**Ένα πλήρες AI Studio. Όλα μέσα από ένα αρχείο.**